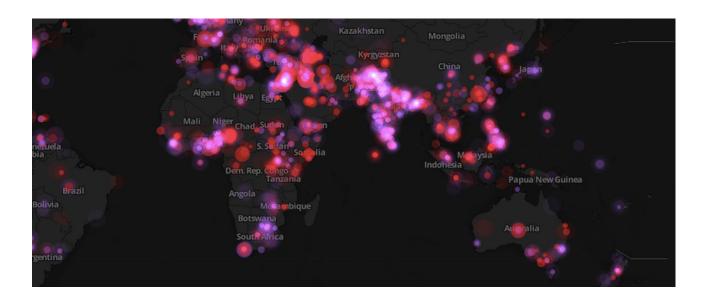
PROJET GDELT 2020

1. Présentation:

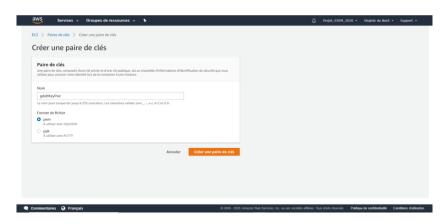
Le but du projet est d'analyser l'année 2020 via la base de données GDELT en utilisant le tone des articles dans les médias des divers pays du monde. "Le projet GDELT est une initiative visant à construire un catalogue de comportements et de croyances à l'échelle de la société humaine dans tous les pays du monde, reliant chaque personne, organisation, lieu, décompte, thème, source d'actualités et événement à travers la planète en un seul massif un réseau qui capture ce qui se passe dans le monde, quel est son contexte et qui est impliqué, et comment le monde en ressent chaque jour. "



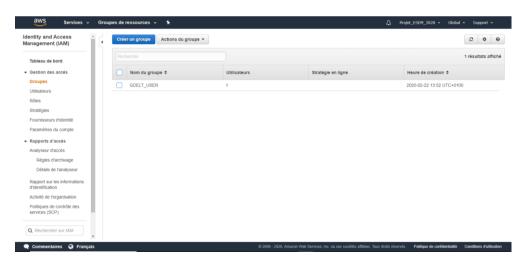
2. Création d'un cluster sur AWS EMR:

- On commence par la création d'une clé privée qui sera automatiquement sauvergardé dans un fichier gdeltKeyPair.pem.
- On utlisira cette clé pour la connexion SSH.

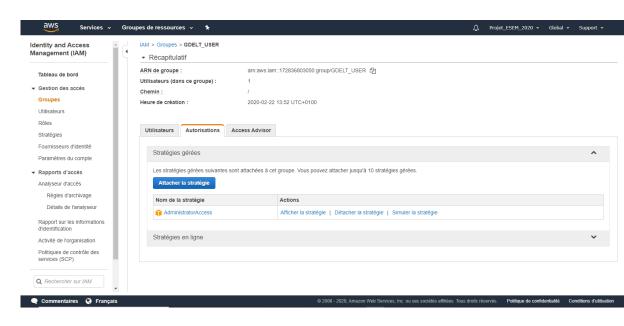
https://console.aws.amazon.com/ec2/home?region=us-east-1#CreateKeyPair:



- Création d'un groupe admin https://console.aws.amazon.com/iam/home?#/groups

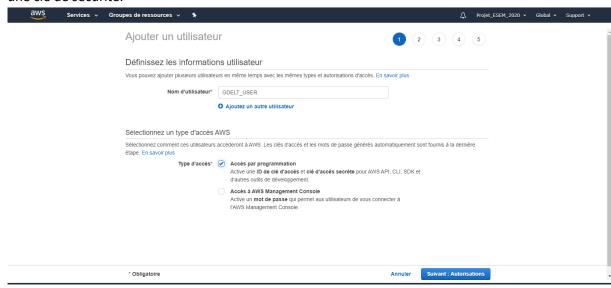


- Choix du type de stratégie : AdministratorAccess

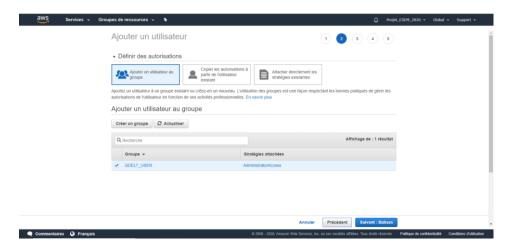


- Ajout d'un utilisateur : GDELT_USER

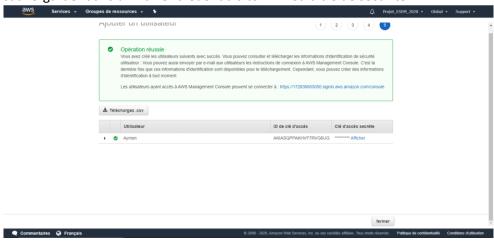
- Choix du type d'accés : « Accées par programmation » afin de créer un ID d'accées et une clé de sécurité.



- Ensuite, on met notre utilisateur dans le groupe administrateur et on valide la création de l'utilisateur.



- Après la validation de la céation de l'utilisateur, on clique sur Téléchargez.csv afin de sauvergarder dans un fichier credentials.csv l'ID et la clé de sécurité.



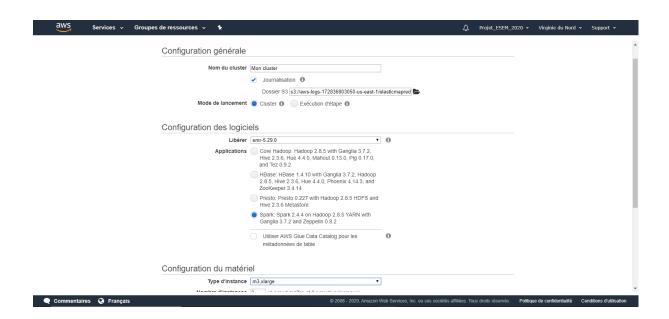
- Démarrage du cluster sur AWS EMR : On crée le cluster en utilisant la console AWS EMR : https://console.aws.amazon.com/elasticmapreduce/home?region=us-east-1#quick-create:
- On définit les paramètres adoptés :

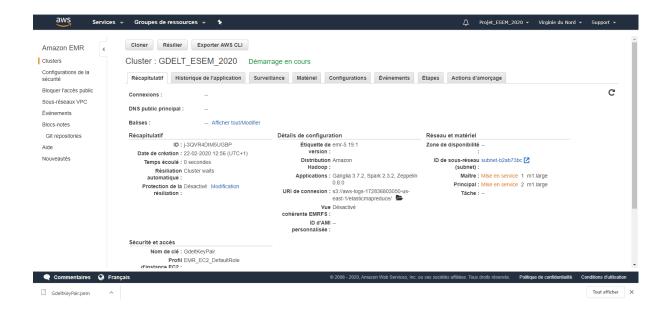
Nom du cluster : Mon cluster

Applications: Spark

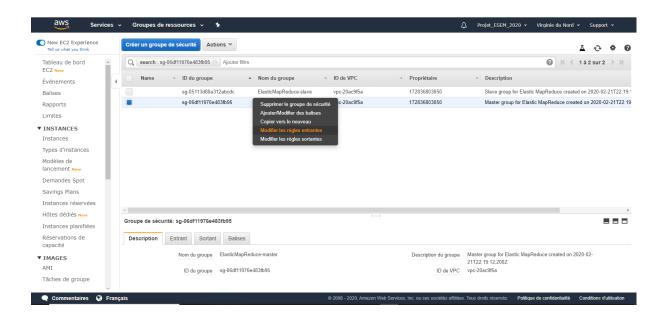
Type d'instance : m3.xlarge

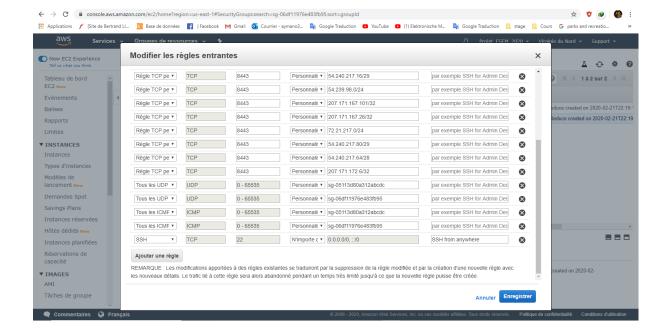
Paire de clés EC2 : gdeltKeyPair



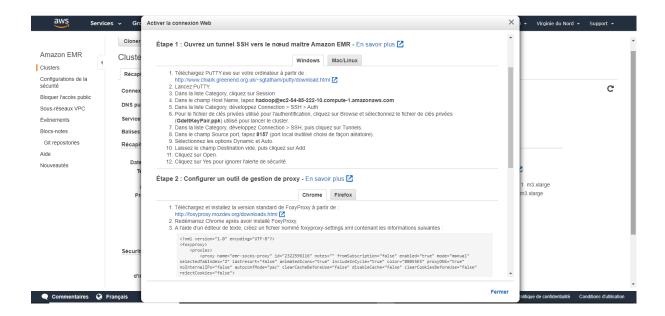


- On rajoute une règle de firewall dans les groupes de sécurité pour le principale node pour permette la connexion SSH.





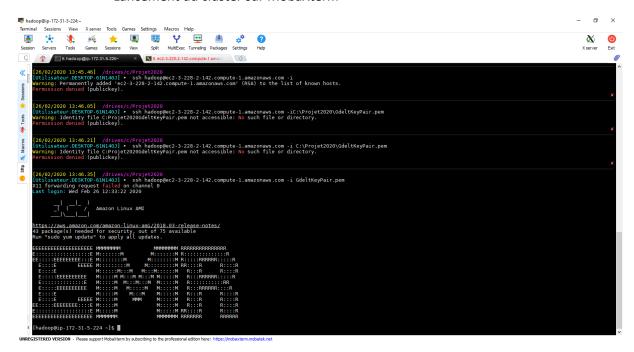
- On a établi un tunnel SSH avec le nœud maître, afin d'accéder aux interfaces Web via http://localhost:PORT.
- On peut aussi utiliser un proxy web (FoxProxy) pour faire directement la translation master-public-dns-name :PORT => localhost:PORT.



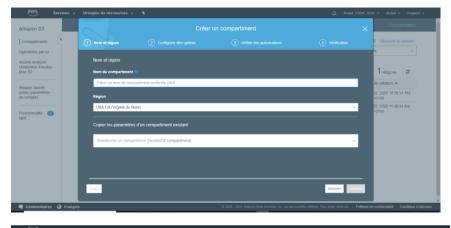
Liste des services et les ports :

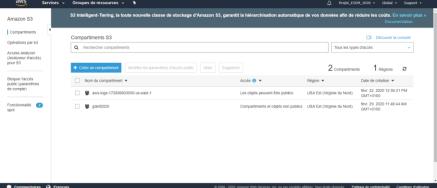
Name of interface	URI
Ganglia	http://master-public-dns-name/ganglia/
Hadoop HDFS NameNode	https://master-public-dns-name:50470/
Hadoop HDFS DataNode	https://coretask-public-dns-name:50475/
HBase	http://master-public-dns-name:16010/
Hue	http://master-public-dns-name:8888/
JupyterHub	https://master-public-dns-name:9443/
Livy	http://master-public-dns-name:8999/
Spark HistoryServer	http://master-public-dns-name:18080/
Tez	http://master-public-dns-name:8080/tez-ui
YARN NodeManager	http://coretask-public-dns-name:8042/
YARN ResourceManager	http://master-public-dns-name:8088/
Zeppelin	http://master-public-dns-name:8890/

Lancement du cluster sur MobaXterm



- Création d'un bucket AWS S3
- On va sur le lien: https://s3.console.aws.amazon.com/s3/home?region=us-east-1





- Connexion à l'interface Zepplin :

Acceder au lien http://master-public-dns-name:8890/ et importation du notebook « _esem_Gdelt_2020.json » dans Zeppelin.



3. ETL GDELT:

Dans notre notebook, on va télécharger les fichiers GDELT pour l'importation des packages

```
import sys.process._
import java.net.URL
import java.io.File
import java.io.File
import java.io.File.{Files, StandardCopyOption}
import java.net.HttpURLConnection
import org.apache.spark.sql.functions._
import sqlContext.implicits._
import java.uitl.zip.ZipInputStream
import java.uitl.zip.ZipInputStream
import java.io.BufferedReader
import java.io.InputStreamReader
import com.amazonaws.services.s3.AmazonS3Client
import com.amazonaws.auth.BasicAWSCredentials
  import com.amazonaws.auth.BasicAWSCredentials
import org.apache.spark.sql.types.IntegerType
import com.amazonaws.services.s3.AmazonS3Client
import sys.process._
import java.net.URL
import java.io.File
import java.io.File
import java.nio.file.{Files, StandardCopyOption}
import java.net.HttpURLConnection
import org.apache.spark.sql.functions._
import sqlContext.implicits._
import org.apache.spark.input.PortableDataStream
import java.util.zip.ZipInputStream
import java.io.BufferedReader
import java.io.InputStreamReader
import org.apache.spark.sql.SQLContext
import com.amazonaws.services.s3.AmazonS3Client
import com.amazonaws.auth.BasicAWSCredentials
import org.apache.spark.sql.types.IntegerType
import com.amazonaws.services.s3.AmazonS3Client
Took 5 sec. Last updated by anonymous at March 07 2020, 2:12:37 PM.
```

Téléchargement des fichiers masterfilelist.txt et masterfile translation.txt

```
%pyspark
inport urllib
print('Beginning file download with urllib2...')
url = 'http://data.gdeltproject.org/gdeltv2/masterfilelist.txt'
urllib.urlretrieve(url, '/tmp/masterfilelist.txt')

Beginning file download with urllib2...
('/tmp/masterfilelist.txt', <httplib.HTTPMessage instance at 0x7fb131b7cbd8>)

Took 2 sec. Last updated by anonymous at March 07 2020, 11:16:52 AM.

%pyspark
import urllib
print('Beginning file download with urllib2...')
url = 'http://data.gdeltproject.org/gdeltv2/masterfilelist-translation.txt", "/tmp/masterfilelist_translation.txt")

Beginning file download with urllib2...
('/tmp/masterfilelist_translation.txt', <httplib.HTTPMessage instance at 0x7fb131b7c8c0>)

Took 1 sec. Last updated by anonymous at March 07 2020, 11:17:01 AM.
```

Récupération du fichier masterfile.txt et le spliter dans un RDD avec 3 colonnes qui sont size, hash et url

```
%pyspark
from pyspark.sql import Row
data_file = sc.textFile('s3://gdelt2020/masterfilelist.txt')
textSplit = data_file.map(lambda line : line.split(" "))
dataRDD = textSplit.map(lambda item : Row (size=item[0], hash=item[1], url=item[2]))
print("succes")
succes
```

Took 0 sec. Last updated by anonymous at March 07 2020, 11:17:12 AM.

```
%pyspark
from pyspark.sql import Row
data_file = sc.textFile('s3://gdelt2020/masterfilelist_translation.txt')
textSplit = data_file.map(lambda line : line.split(" "))
dataRDD_translation = textSplit.map(lambda item : Row (size=item[0], hash=item[1], url=item[2]))
print("succes")
succes
```

Took 0 sec. Last updated by anonymous at March 07 2020, 11:23:03 AM.

Affichage du ficher RDD

```
| System | Artificial System | State | System |
```

Conversion du fichier RDD to data frame

```
%pyspark
dataDF = dataRDD.toDF()
```

Took 19 sec. Last updated by anonymous at March 07 2020, 1:00:12 PM.

Affichage du data frame

Création d'un data frame avec une seule colonne « url »

Sélection de tous les urls « export »

Sélection de tous les urls « mentions »

Took 10 sec. Last updated by anonymous at March 07 2020, 1:21:16 PM.

Création d'une liste avec tous les urls de 2019



1 display(list_2019)

size	hash	uri	
149183	50e8534eece514f98fb184e6b36ecd94	http://data.gdeltproject.org/gdeltv2/20190101000000.export.CSV.zip	
136583	cb61605430b6813d9ae2d60f72cf4c8f	http://data.gdeltproject.org/gdeltv2/20190101000000.mentions.CSV.zip	
6415898	5837cd0fcbdfe0f37d528e262bb4ebe2	http://data.gdeltproject.org/gdeltv2/20190101000000.gkg.csv.zip	
116538	b4869e9de5039dbd0db3841b826362cf	http://data.gdeltproject.org/gdeltv2/20190101001500.export.CSV.zip	
139610	6dbea3ed9bfee3d824ebf84f3a33a140	http://data.gdeltproject.org/gdeltv2/20190101001500.mentions.CSV.zip	
6769390	d8ef6f41fb4859456f0a8f5f51a47c4d	http://data.gdeltproject.org/gdeltv2/20190101001500.gkg.csv.zip	
103092	4ed6e5d871807c2791710c2a5a3f0c07	http://data.gdeltproject.org/gdeltv2/20190101003000.export.CSV.zip	
131103	2d3c9ffe3133666b5d20916b801310e4	http://data.gdeltproject.org/gdeltv2/20190101003000.mentions.CSV.zip	
Showing the first 1000 rows	ha72aa601a6aa620haEdEbh201a671E6	http://data.adaltarajast.org/adalts/2/20100101002000.alva.cov.zip	



Command took 2.04 seconds -- by mansour.hmdn@gmail.com at 07/03/2020 à 12:14:30 on unknown cluster

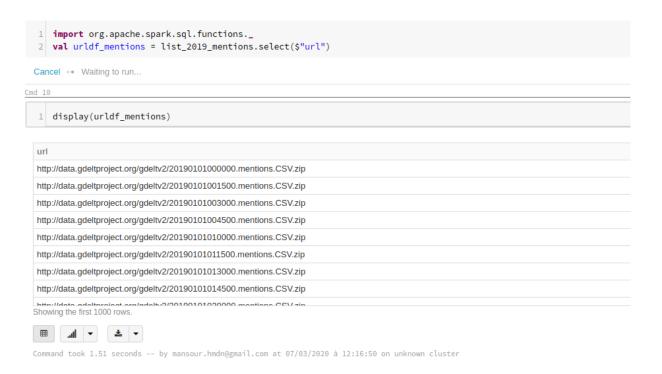
Les urls « mentions » de l'année 2019



▶ ■ list_2019_mentions: org.apache.spark.sql.Dataset[org.apache.spark.sql.Row] = [size: string, hash: string ... 1 more fields]



■ ★ ▼



Création d'un alarme de consommation : On a créé une alarme de facturation qui envoie un message électronique lorsque les frais estimés pour AWS dépassent un seuil spécifié (100 euros)

